TRABAJO PRÁCTICO

Ciencia de Datos Aplicada al Transporte

Análisis Espacial y Modelización Aplicada a la Inseguridad Vial de la Ciudad Autónoma de Buenos Aires (CABA)

Índice de Contenidos

Introducción 2

1. Ingeniería de datos, limpieza y perfilado exploratorio 2

- 1.1 Diagnóstico de integración de datos
- 1.2 Normalización de variables
- 1.3 Análisis temporal
- 1.4 Perfil demográfico
- 1.5 Horas pico

2. Sistemas de proyección geográfica e ingeniería espacial .. 3

- 2.1 GeoDataFrame y visualización estándar (WGS84)
- 2.2 Tratamiento geoespacial avanzado (Gauss-Kruger CABA)
- 2.3 Cálculo de distancias euclidianas métricas

3. Análisis espacio-categorial, segmentación y discretización 5

- 3.1 Cartografía por modo de desplazamiento (FacetGrid)
- 3.2 Discretización espacial por el método de Jenks
- 3.3 Análisis espacial por agregación política (Comunas)

4. Algoritmos no supervisados de Machine Learning 8

- 4.1 Modelización DBSCAN y análisis de sensibilidad
- 4.2 Confrontación de modelos: DBSCAN vs. K-Means

5. Análisis avanzado: H3, grafos urbanos e impacto operativo 11

- 5.1 Indexación geoespacial hexagonal H3 (Uber)
- 5.2 Top 10 hexágonos críticos
- 5.3 Topología de la red vial (OSMnX)
- 5.4 Siniestralidad vs. complejidad topológica
- 5.5 Perfilado de sectores y validación geográfica

Conclusión General y limitaciones del estudio 13

Introducción

El objetivo de este proyecto es estructurar, analizar y modelizar los datos de accidentalidad vial de la Ciudad Autónoma de Buenos Aires (CABA) para identificar de manera objetiva las zonas de acumulación de siniestros graves y mortales. La metodología sigue una progresión rigurosa que va desde la limpieza de datos brutos hasta la aplicación de algoritmos no supervisados de Machine Learning.

Estructura del archivo de datos

HECHOS: Tabla principal. Cada fila es un accidente identificado por un ID único, con variables temporales, espaciales y tipos de vehículos implicados.

VÍCTIMAS: Cada fila corresponde a una persona afectada. Un mismo accidente puede tener varias víctimas (relación uno a muchos). Contiene edad, sexo y modo de transporte.

DICCIONARIOS: Metadatos y definiciones de cada columna.

Definiciones de gravedad

MORTAL: Persona cuyo fallecimiento ocurre dentro de los 30 días posteriores al accidente.

GRAVE: Persona hospitalizada durante al menos 24 horas.

SD (Sin Datos): Asimilado estadísticamente a un caso leve (usuario no hospitalizado).

Tipos de víctimas

- Peatón
- Bicicleta
- Moto
- Auto
- Transporte Público (Bus / Colectivo)

Problematica

¿Cómo identificar con precisión científica los puntos negros de accidentalidad grave en Buenos Aires para orientar las políticas públicas de seguridad vial?

1. Ingeniería de datos, limpieza y perfilado exploratorio

1.1 Diagnóstico de integración de datos

La unión interna (inner join) consolidó un total de 62 076 registros. Este incremento de volumen se explica porque la tabla VÍCTIMAS se encuentra en un nivel de granularidad inferior: varias víctimas pueden estar vinculadas a un mismo identificador de hecho en la tabla HECHOS.

Asimismo, los registros sin información explícita (`SD`) fueron estandarizados bajo el formato de valores nulos (`NaN`), preparando la base de datos para la aplicación de filtros de criticidad y algoritmos geométricos.

1.2 Normalización de variables

Se ejecutó una fase de normalización estructural: corrección de inconsistencias en las etiquetas originales (como la alternancia de mayúsculas en `GRAVEdad_victima`) hacia una nomenclatura unificada en `snake_case`. Las variables categóricas principales (`modo_transporte` y `sexo_victima`) fueron convertidas a mayúsculas con `.str.upper().str.strip()`, eliminando el riesgo de fragmentación artificial en los análisis posteriores.

1.3 Análisis temporal

```
--- Días más peligrosos de la semana ---
  dia_semana  cantidad_siniestros
0    Viernes                10340
1     Jueves                 9892
2  Miércoles                 9678
3     Martes                 9640
4      Lunes                 9135
5     Sábado                 7441
6    Domingo                 5950
```

El análisis de los siniestros según el día de la semana revela un patrón claro vinculado a los ciclos de actividad laboral y comercial de la ciudad. Los días hábiles concentran la mayor cantidad de accidentes, registrando un crecimiento constante a medida que avanza la semana laboral. El viernes se consolida como el día más peligroso con más de 10,300 casos, seguido de cerca por el jueves y el miércoles. Este comportamiento demuestra que la acumulación de cansancio semanal, combinada con la prisa habitual de los días laborales y el aumento de los desplazamientos particulares o de logística en las jornadas previas al fin de semana, incrementa drásticamente los factores de riesgo en la vía pública.

Por el contrario, durante el fin de semana se observa un descenso marcado en el volumen absoluto de siniestros, alcanzando su punto mínimo el domingo con menos de 6,000 registros. Esta reducción se explica principalmente por la drástica disminución del flujo vehicular de transporte público, servicios comerciales y camiones de carga que habitualmente congestionan la red vial. Desde la perspectiva de la gestión pública, estos datos demuestran que el riesgo está fuertemente asociado a la intensidad y densidad del tránsito diario, lo que sugiere que las campañas de prevención y los controles de tráfico deben reforzarse de manera prioritaria durante los días laborables, especialmente en la transición hacia el final de la semana.

1.4 Perfil demográfico: el género frente al riesgo

```
--- Perfil demográfico de las víctimas ---
  sexo_victima gravedad_siniestro  edad_promedio  total_casos
0            F              GRAVE      42.263021          784
1            F               LEVE      40.240867        16395
2            F             MORTAL      51.355030          177
3            M              GRAVE      37.043887         1930
4            M               LEVE      36.444842        31244
5            M             MORTAL      40.702128          492
```

El agrupamiento por factores demográficos revela disparidades sociológicas mayores frente a la exposición al riesgo vial:

Asimetría de género pronunciada: Sobre un volumen global de aproximadamente 51 000 víctimas analizadas, la población masculina concentra la casi totalidad de la siniestralidad. Los hombres registran una proporción del simple al doble en heridas leves (31 244 casos masculinos frente a 16 395 femeninos) y una supermortalidad que alcanza un factor de casi tres en la categoría de fallecimientos (492 hombres fallecidos frente a 177 mujeres).

Efecto de edad y cinética de gravedad: Existe una correlación directa entre el aumento de la edad media y el agravamiento del desenlace del siniestro:

- **Mujeres:** la edad media progresa de 40,24 años para heridas leves (LEVE) a 42,26 años para heridas graves, y culmina en 51,35 años para los accidentes mortales.
- **Hombres:** la trayectoria asciende de 36,44 años (LEVE) a 37,04 años (GRAVE) para alcanzar 40,70 años en los fallecimientos.

Los hombres representan cerca del 73% de los accidentes mortales. La correlación directa entre edad y vulnerabilidad —con una edad media de más de 51 años para las mujeres fallecidas— sugiere una menor resiliencia física de los usuarios mayores ante los impactos.

1.5 Análisis de horas pico: modelos de movilidad pendular

```
--- Análisis de horas pico (Conversión validada) ---
Siniestros en hora pico matutina (07:00 - 09:59): 7940
Siniestros en hora pico vespertina (16:00 - 18:59): 12877

Eficiencia de la conversión: 61984 / 62076 registros procesados.
```

La implementación de un parser de extracción horaria a medida permitió aislar numéricamente la componente horaria del accidente, garantizando la conversión válida de **61 984 filas** del dataset.

La cuantificación de los volúmenes en las franjas de desplazamientos pendulares de amplitud fija de 3 horas arroja los siguientes resultados:

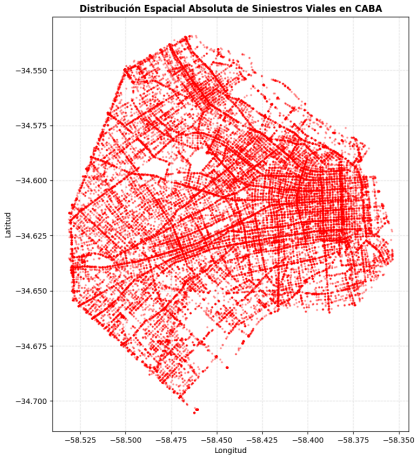
- **Punta de la mañana (07:00–09:59):** 7 940 accidentes registrados.
- **Punta de la tarde (16:00–18:59):** 12 877 accidentes registrados.

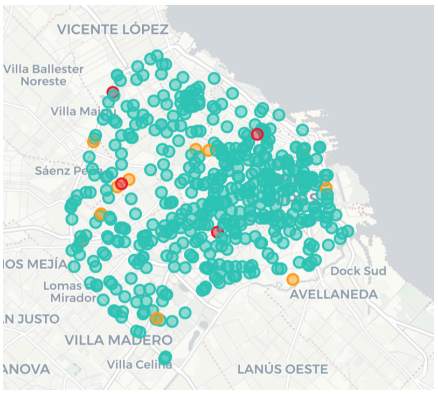
El análisis confirma el impacto de la movilidad pendular en la accidentalidad. Sin embargo, se observa una asimetría mayor: la punta vespertina es un **62% más accidentogéna** que la matutina. Factores cumulativos explican este fenómeno: la fatiga acumulada a lo largo de la jornada laboral, las condiciones de luminosidad más bajas (fin del día) y los flujos de desplazamiento más desordenados (compras, salidas post-trabajo que se superponen al retorno al hogar), a diferencia de la mañana donde los trayectos son más directos y normados.

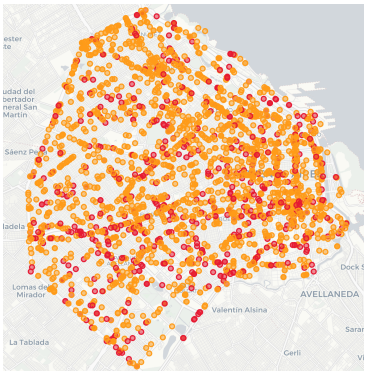
2. Sistemas de proyección geográfica e ingeniería espacial métrica

El objetivo de esta sección es explotar la dimensión espacial de los datos. Para ello, es indispensable comprender la divergencia entre un referencial de coordenadas geográficas (angulares sobre modelo esférico) y un sistema proyectado local (métrico sobre plano de vialidad).

2.1 Construcción del GeoDataFrame y visualización estándar (WGS84)







Se inicializa la dimensión geoespacial a través de GeoPandas, vinculando las coordenadas de latitud y longitud brutas bajo el sistema mundial de referencia WGS84, correspondiente al código de identificación `EPSG:4326`.

La ejecución gráfica global del conjunto de puntos de accidentes mediante el método `.plot(alpha=0.3)` traza de manera orgánica la configuración física del tejido urbano de CABA, haciendo resaltar por superposición de intensidad la trama de las grandes avenidas y ejes autopistas mayores.

2.2 Tratamiento geoespacial avanzado de la coordenada plana (Gauss-Kruger)

El conjunto de datos contiene la columna textual `geocodificacion_plana` expresada bajo la forma `POINT (X Y)`. Estos valores siguen las especificaciones métricas de la proyección local oficial **Gauss-Kruger CABA**. Sin embargo, la escritura de este campo integra una anomalía tipográfica regional (presencia de puntos dobles como separadores de miles, por ejemplo `100.937.5`). Se aplica un tratamiento por expresiones regulares (re) para normalizar el formato Well-Known Text (WKT) y permitir su interpretación geométrica por la biblioteca `shapely.wkt`.

2.3 Modelización y cálculo de distancias euclidianas métricas

```
--- Represenación Métrique Reparada (Gauss-Kruger CABA) ---
      id_siniestro                     geometry
0  LC-2019-0000445  POINT (94371.442 102884.194)
1  LC-2019-0000445  POINT (94371.442 102884.194)

--- Variable espacial creada con éxito ---
      id_siniestro  distancia_obelisco_km
0  LC-2019-0000445              13.162842
1  LC-2019-0000445              13.162842
2  LC-2019-0000445              13.162842
3  LC-2019-0000194              14.591402
4  LC-2019-0000329               5.763198

 Reproyección exitosa al estándar global WGS84 (EPSG:4326).
```

A fin de realizar medidas físicas lineales reales (expresadas en metros o kilómetros) y evitar las distorsiones matemáticas inherentes a los cálculos de coordenadas angulares en grados, el GeoDataFrame se proyecta en el sistema de coordenadas métricas local de la capital. Para evitar las limitaciones de indexación del código de proyección en el entorno, la definición matemática exacta se especifica mediante la sintaxis de configuración `PROJ4`.

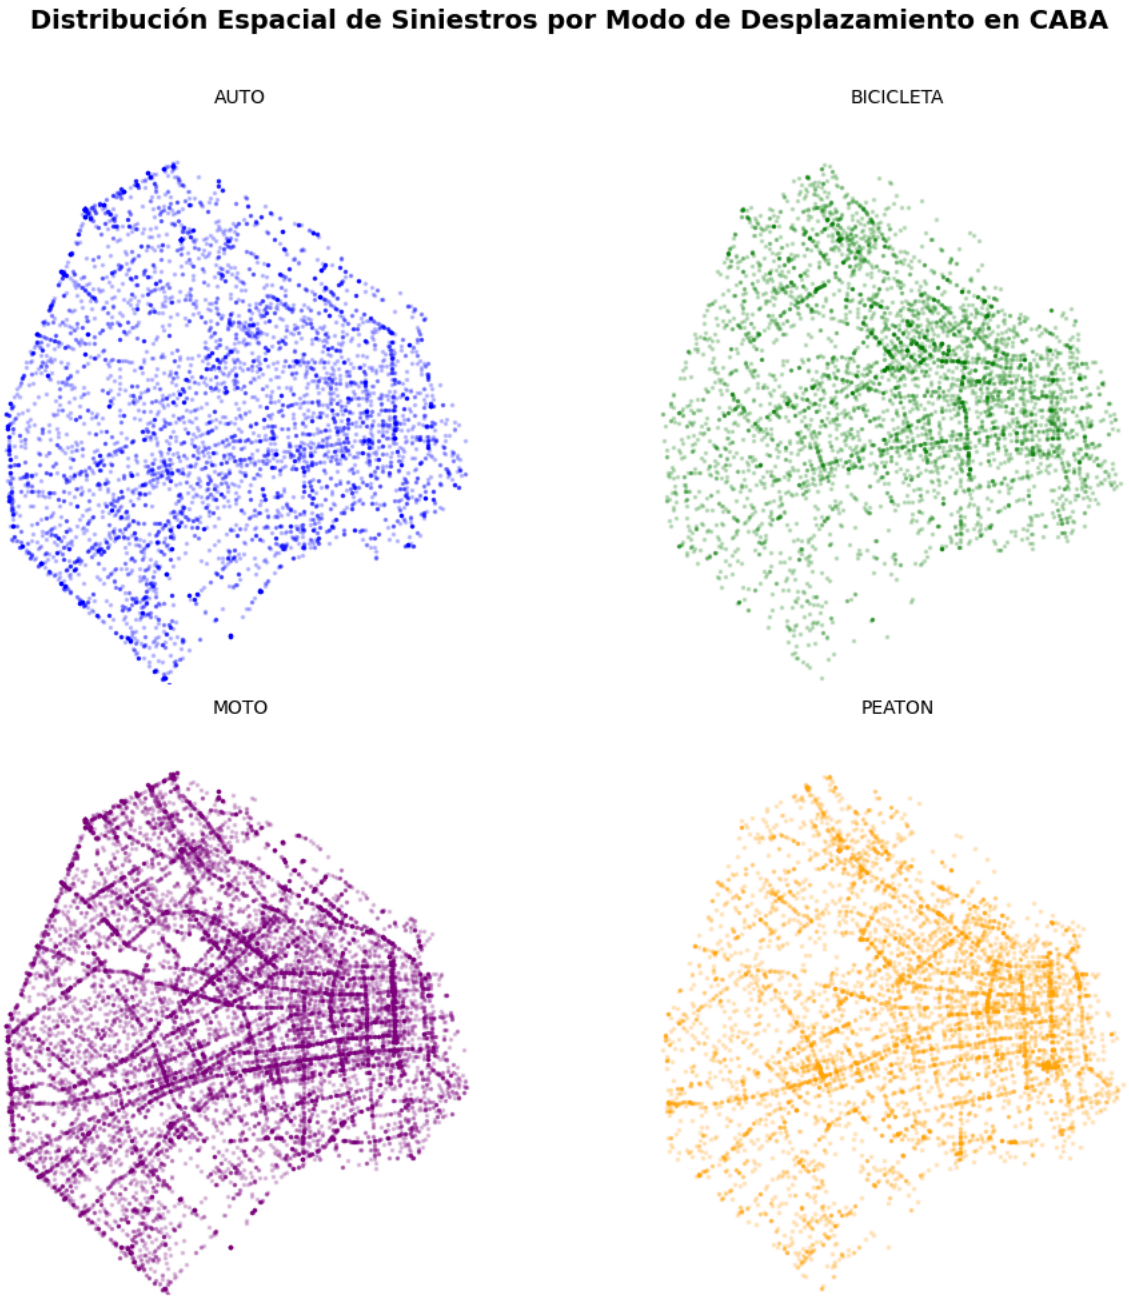
Este método permite atribuir de forma estable a cada accidente vial su distancia lineal exacta en kilómetros (`distancia_obelisco_km`) respecto al punto central de actividad de la metrópolis.

Los resultados muestran que el indicador funciona bien y es consistente: mientras que el siniestro más cercano está en pleno radio céntrico a solo 5.76 kilómetros, otros registros se ubican en la periferia profunda de la ciudad, superando los 13 y 14 kilómetros de distancia del Obelisco.

Disponer de esta distancia exacta en kilómetros es clave para el informe, ya que nos sirve para analizar y modelar estadísticamente cómo cambia el perfil del riesgo vial en Buenos Aires a medida que nos alejamos del centro urbano denso y congestionado para entrar en los corredores de tránsito rápido de los límites de la Capital.

3. Análisis espacio-categorial, segmentación y discretización

3.1 Cartografía comportamental por modo de desplazamiento (FacetGrid)



La explotación de las variables combinadas geoespaciales y operacionales se materializa en la generación de un gráfico multi-panel (`sns.FacetGrid`) segmentado por tipo de transporte usuario, restringido a los límites estrictos del perímetro urbano de CABA.

La interpretación de la distribución espacial de los cuatro submapas pone en evidencia comportamientos de desplazamiento heterogéneos y estructurales:

MOTO (Violeta) – Riesgo sistémico y lineal: Representa la capa espacial más densa y saturada. Los accidentes de motociclistas se extienden uniformemente sobre el conjunto de la trama vial de la capital, dibujando con nitidez los ejes secundarios como las grandes avenidas radiales. El riesgo es ubicuo.

AUTO (Azul) – Concentración en los corredores de alta velocidad: La siniestralidad se aglomera de forma preponderante sobre el arco periférico oeste, materializando la autopista Avenida General Paz, así como sobre la arteria autopista Lugones que bordea la franja costera septentrional. Los accidentes de automóviles se concentran en las infraestructuras de tránsito caracterizadas por velocidades de explotación elevadas.

PEATÓN (Naranja) – Polarización en los nodos de intermodalidad central: A diferencia del modelo del automóvil, el riesgo peatonal se polariza exclusivamente en la franja oriental de la ciudad. Esta zona concentra el centro financiero y administrativo (Microcentro), así como los grandes nodos de correspondencia de transporte colectivo (Retiro, Constitución, Once), donde las densidades de flujos peatonales cruzan las trayectorias de transporte de superficie.

BICICLETA (Verde) – Fricción espacial en la red de vialidad compartida: Los accidentes de ciclistas se despliegan preferentemente en el corredor residencial y comercial del eje Noreste (Palermo, Belgrano). Los puntos de impacto se distribuyen a lo largo de las mallas secundarias, revelando las zonas de conflicto de circulación donde las bicicletas comparten la calzada en ausencia de vías dedicadas y separadas.

3.2 Discretización espacial estadística por el método de Jenks

Para analizar la influencia de la distancia respecto al hipercentro sobre el nivel de gravedad del siniestro, se aplica el algoritmo de rupturas naturales Fisher-Jenks (`mapclassify.NaturalBreaks`) parametrizado para generar 3 anillos de sectorización espacial optimizada.

La extracción de la matriz de contingencia normalizada genera los siguientes resultados estadísticos:

Zona de distancia (Jenks)	Tasa GRAVE	Tasa LEVE	Tasa MORTAL
Centro (0–3 km)	4,00 %	94,86 %	1,14 %
Macrocentro / Barrios (3–8 km)	4,10 %	94,58 %	1,32 %
Periferia (>8 km)	3,77 %	96,23 %	0,00 %

Estos resultados ponen en evidencia una realidad empírica contraintuitiva. Los modelos de transporte clásicos vinculan generalmente la periferia urbana a tasas de letalidad más elevadas debido a las velocidades autopistas. Los datos reales de Buenos Aires invalidan este esquema teórico: la tasa de accidentes mortales culmina en la corona intermedia (3 a 8 km del Obelisco, con 1,32% de casos mortales) y se anula estadísticamente en la gran periferia (0,00% de casos mortales).

Esta configuración se explica por dos dinámicas geoespaciales:

1. Intensidad de fricción en la zona intermedia: La zona comprendida entre 3 y 8 kilómetros engloba los grandes nodos de tránsito de alta densidad (Palermo, Flores, Caballito). Es en este territorio donde se cruzan ejes viales de alto caudal y flujos masivos de usuarios vulnerables (motos, peatones, bicicletas) interactuando en intersecciones complejas.

2. Sesgo de sobrerrepresentación de colisiones leves en la periferia: La periferia vial (en particular el eje de la General Paz) concentra una tasa de accidentes leves (LEVE) del 96,23%. Este valor refleja la recurrencia de las colisiones en cadena (choques traseros) ocurridos a baja velocidad durante los episodios de congestión en horas pico. Este alto volumen de siniestros materiales o benignos aplasta estadísticamente la parte relativa de los accidentes mortales en este sector.

3.3 Análisis espacial por agregación política (Comunas)

Al aplicar la lógica de agregación espacial por polígonos administrativos, se contabiliza el volumen absoluto de la siniestralidad mayor (GRAVE y MORTAL) por Comuna. El ranking extrae el Top 5 de las Comunas que muestran los índices de peligrosidad más críticos:

Comuna 1 (332 accidentes graves): Se posiciona ampliamente a la cabeza. Este municipio cubre el centro financiero, administrativo e histórico (Retiro, San Nicolás, Puerto Madero, San Telmo, Montserrat, Constitución). Es el punto de convergencia mayor de las redes de transporte guiado (metro, terminales ferroviarias) y las líneas de bus, lo que induce una densidad peatonal extrema en situación de conflicto permanente con el tráfico de superficie.

Comuna 12 (266 accidentes graves): Ocupa la segunda posición. Constituye la puerta de acceso Norte de la metrópolis, zona de intercambio mayor que conecta los flujos de tránsito provenientes de las autopistas Avenida General Paz y Panamericana.

Comunas 14 (263 casos) y 13 (232 casos): Representan el nodo de desarrollo septentrional (Palermo, Belgrano, Núñez). Estos sectores se caracterizan por densidades residenciales y comerciales particularmente elevadas, una importante actividad nocturna, y son atravesados por grandes ejes radiales saturados (Avenida Santa Fe, Avenida Cabildo).

El análisis agregado por polígonos (Comunas) demuestra que la inseguridad vial mayor se concentra en dos polos: el hiper-centro hiper-conectado (Comuna 1, líder con 332 accidentes graves) debido a la saturación de los flujos multimodales, y el eje Norte/Noroeste (Comunas 12, 14 y 13), caracterizado por altas densidades residenciales y comerciales atravesadas por ejes de penetración de alto caudal.

4. Algoritmos no supervisados de Machine Learning e identificación de puntos negros

A fin de eliminar la subjetividad humana inherente al recorte por zonas administrativas y localizar con precisión las intersecciones que necesitan aménagements de seguridad vial, se implementan enfoques de clustering espacial aplicados al dataset de accidentes prioritarios (3 056 casos GRAVE y MORTAL).

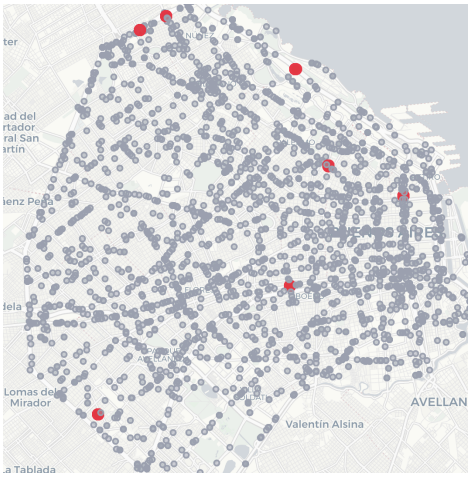
4.1 Modelización DBSCAN y análisis de sensibilidad de hiperparámetros

El algoritmo **DBSCAN** (Density-Based Spatial Clustering of Applications with Noise) es seleccionado por sus propiedades matemáticas adaptadas a las problemáticas de transporte. Permite descubrir el número de clusters de manera endógena, adaptarse a formas de geometrías complejas (a lo largo de trazados viales lineales) y aislar los eventos dispersos clasificándolos como ruido informático.

Para liberarse de las deformaciones geométricas de la distancia euclidiana sobre un plano, las posiciones de latitud y longitud se convierten en radianes, y se especifica la métrica de cálculo de distancia de **Haversine**. El radio de búsqueda épsilon se modula en función del radio medio de la Tierra (6371.0088 km).

Se probaron tres configuraciones de hiperparámetros para evaluar la respuesta del modelo y optimizar la identificación de los puntos negros urbanos:

Escenario	Radio (ε)	Umbral (min)	Puntos negros	Accidentes captados	Perfil operativo
A (Quirúrgico)	50 m	10	8	95 / 3 056 (3%)	Ultra-crítico (intersecciones mortales)
Estándar (Inicial)	100 m	8	24	251 / 3 056 (8%)	Ideal (Gestión municipal focalizada)
B (Barrial / Eje)	250 m	15	24	508 / 3 056 (16%)	Global (Aménagement de grandes vías)



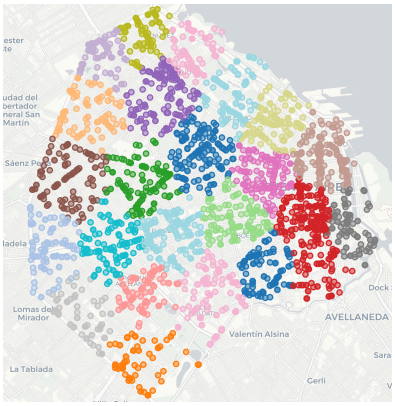
Discusión sobre la sensibilidad de los hiperparámetros

Escenario A (eps=50 m, min=10): Extremadamente restrictivo. Al limitar el radio a una escala micro-urbana (el equivalente de media cuadra argentina), el algoritmo solo detecta 8 puntos negros. Es una visión quirúrgica: las zonas encontradas son las intersecciones más peligrosas y prioritarias de toda la Ciudad Autónoma de Buenos Aires. Sin embargo, deja de lado el 97% de los accidentes graves, lo que resulta demasiado restrictivo para una política global de seguridad vial.

Escenario B (eps=250 m, min=15): Cambia radicalmente de escala. Con un radio ampliado (el equivalente de 2,5 cuadras), el algoritmo agrupa mucho más fácilmente los eventos. Captura 508 accidentes (16% del total). Este escenario ya no aísla cruces precisos, sino que pone en evidencia ejes o porciones de avenidas enteras que estructuran el peligro. Es ideal para planificar aménagements pesados (velocidad, oleadas verdes de semáforos de señalización).

Escenario Estándar (eps=100 m, min=8): Representa el compromiso operativo ideal. Aísla 24 puntos negros distintos, un tamaño de objetivo manejable para los equipos técnicos de la ciudad, conservando al mismo tiempo una precisión espacial a la escala de un cruce o de una curva precisa.

4.2 Confrontación de modelos: validación por comparación con K-Means



A fin de validar rigurosamente la adecuación de DBSCAN, se ejecuta en paralelo el algoritmo de particionamiento tradicional **K-Means**, fijando de manera iterativa la restricción de generación a un número idéntico de agrupamientos: K = 24 clusters.

La comparación de las estructuras de particionamiento pone en evidencia la superioridad algorítmica de DBSCAN frente a los límites estructurales del enfoque por K-Means para el análisis espacial del transporte:

La ausencia total de «ruido»: K-Means forzó cada accidente a integrarse en un grupo, incluso aquellos completamente aislados en los extremos de la ciudad. Para el municipio, no tiene sentido invertir en un aménagement pesado donde un solo accidente se produjo de manera aislada.

Polígonos puramente geométricos: El algoritmo simplemente cortó Buenos Aires en zonas geográficas compactas y circulares. No comprende si los accidentes siguen una línea de metro o una gran avenida; simplemente agrupa lo que está próximo geométricamente.

Inutilizabilidad operativa: Si se le dice a la ciudad de Buenos Aires «la zona rosa del sur es un cluster peligroso», la zona es tan inmensa que no sabrán si hay que intervenir en un cruce, una avenida o una curva en particular. DBSCAN, al contrario, señala una intersección de 100 metros.

5. Análisis avanzado: H3, grafos urbanos e impacto operativo

5.1 Indexación geoespacial hexagonal H3 (Uber) – Resolución 8

Para mitigar las restricciones metodológicas del particionamiento por Comunas (cuyos límites políticos son asimétricos y arbitrarios), se implementó un sistema de indexación espacial discreta basado en la biblioteca jerárquica **H3 de Uber**. El espacio continuo de CABA se teseló en celdas hexagonales regulares bajo una calibración de **Resolución 8** (donde el radio de cada celda es de aproximadamente 460 metros, es decir ~0,7 km²).

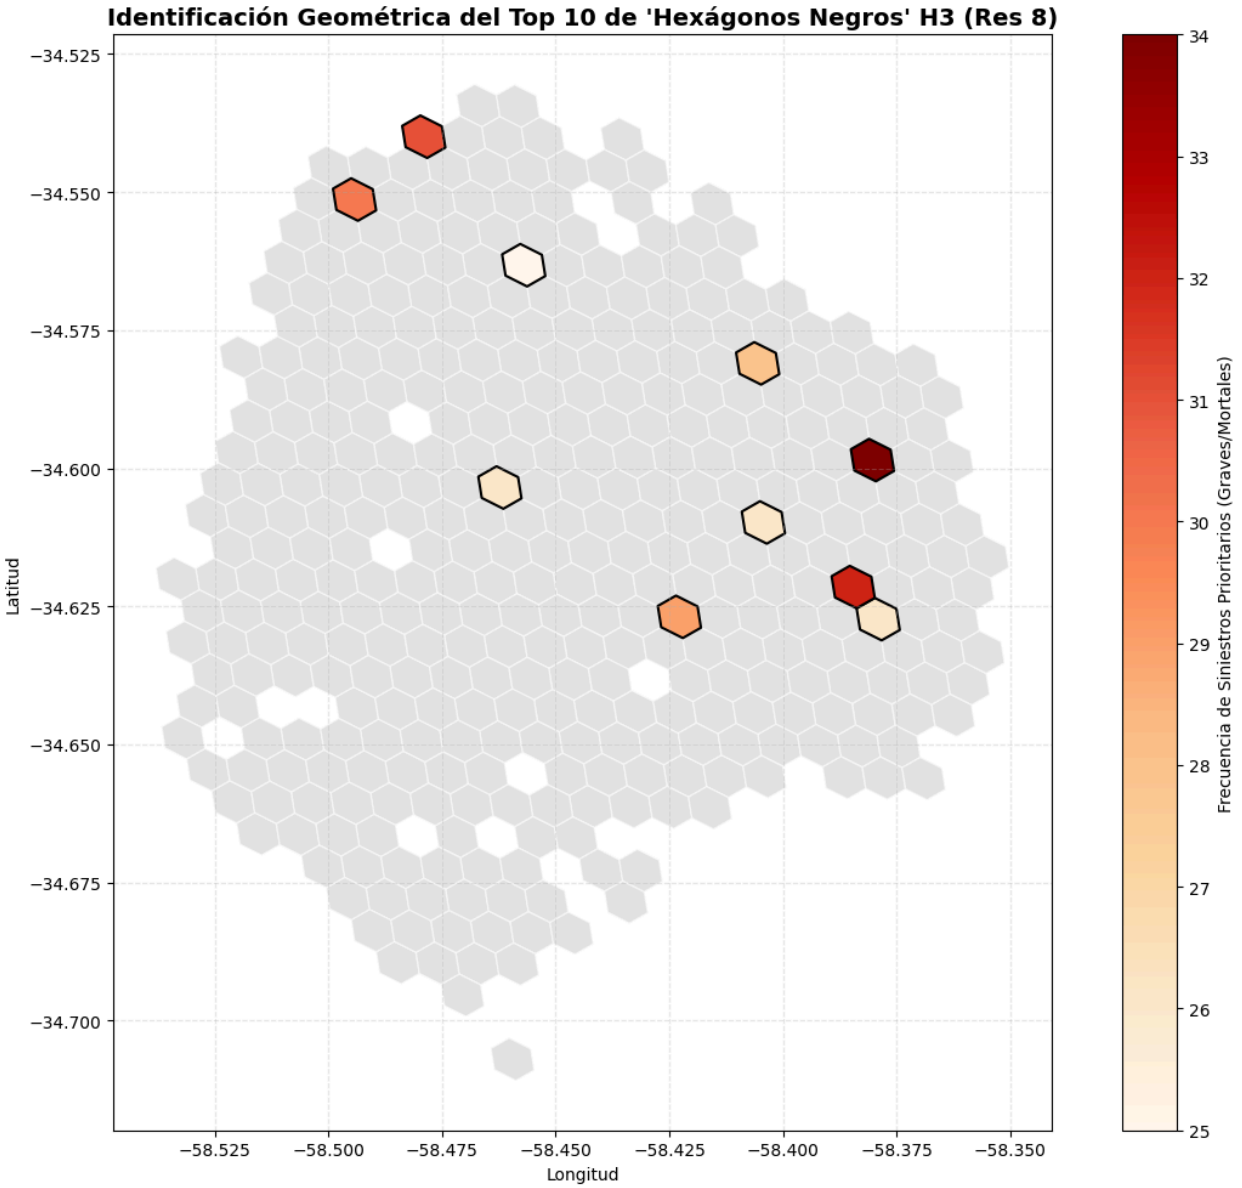
La geometría hexagonal ofrece ventajas analíticas críticas frente al uso de mallas cuadradas tradicionales:

- **Isotropía de vecindad:** La distancia entre el centro de un hexágono y sus seis vecinos inmediatos es idéntica y constante. Esto elimina las distorsiones de esquina asociadas a los cuadrados, garantizando que los cálculos de densidad de siniestros sean uniformes en todas las direcciones de la trama urbana.
- **Estabilidad operativa:** Al agrupar los datos en celdas estandarizadas de 0,7 km², el ranking resultante aísla los «macro-hotspots» de riesgo de forma independiente a las divisiones políticas de las Comunas.

5.2 Top 10 hexágonos críticos

Los diez hexágonos con mayor concentración de siniestros graves se distribuyen entre 25 y 34 casos por celda, lo que es estadísticamente significativo dado el tamaño del perímetro analizado. Geográficamente, los hexágonos más críticos se localizan sobre el trazado de la Avenida General Paz (frontera curva al oeste/norte) y en la zona de la Comuna 1 / Retiro / Puerto Madero (punta este junto al río), donde la densidad de tráfico es máxima.

Posición	Siniestros graves
Top 1 – Hexágono 88c2e31ad9fffff	34
Top 2 – Hexágono 88c2e31103fffff	32
Top 3 – Hexágono 88c2e30219fffff	31
Top 4 – Hexágono 88c2e31567fffff	30
Top 5 – Hexágono 88c2e31029fffff	29
Top 6 – Hexágono 88c2e311abfffff	28
Top 7 – Hexágono 88c2e310e9fffff	26
Top 8 – Hexágono 88c2e31101fffff	26
Top 9 – Hexágono 88c2e31113fffff	26
Top 10 – Hexágono 88c2e30241fffff	25



5.3 Topología de la red vial urbana (OSMnX)

El análisis geoespacial de la siniestralidad prioritaria se enriquece mediante la incorporación de la topología real de la red vial urbana. La utilización de la biblioteca **OSMnX** permite modelar CABA como un grafo matemático dirigido, donde las aristas representan los tramos de circulación y los nodos (`gdf_nodos_viales`) constituyen las intersecciones o cruces físicos de la infraestructura.

Al vectorizar los **17 910 nodos** de la red bajo el sistema `EPSG:4326`, el dataset queda completamente preparado para realizar operaciones de análisis espacial por proximidad (Spatial Join). Esto permite cruzar las coordenadas de los «puntos negros» (DBSCAN) y de los «hexágonos críticos» (H3) con los atributos geométricos de las esquinas reales de Buenos Aires.

5.4 Siniestralidad vs. complejidad topológica

Al evaluar los resultados del Top 10 bajo esta nueva dimensión topológica, se evidencian dos fenómenos estructurales:

Hexágono H3	Siniestros graves	Total esquinas	Complejidad media (vías)
88c2e31ad9fffff	34	43	3,93
88c2e31103fffff	32	51	3,61
88c2e30219fffff	31	61	3,46
88c2e31567fffff	30	81	3,57
88c2e31029fffff	29	51	3,59
88c2e311abfffff	28	50	3,42
88c2e310e9fffff	26	47	3,79
88c2e31101fffff	26	53	3,47
88c2e31113fffff	26	32	3,88
88c2e30241fffff	25	46	3,93

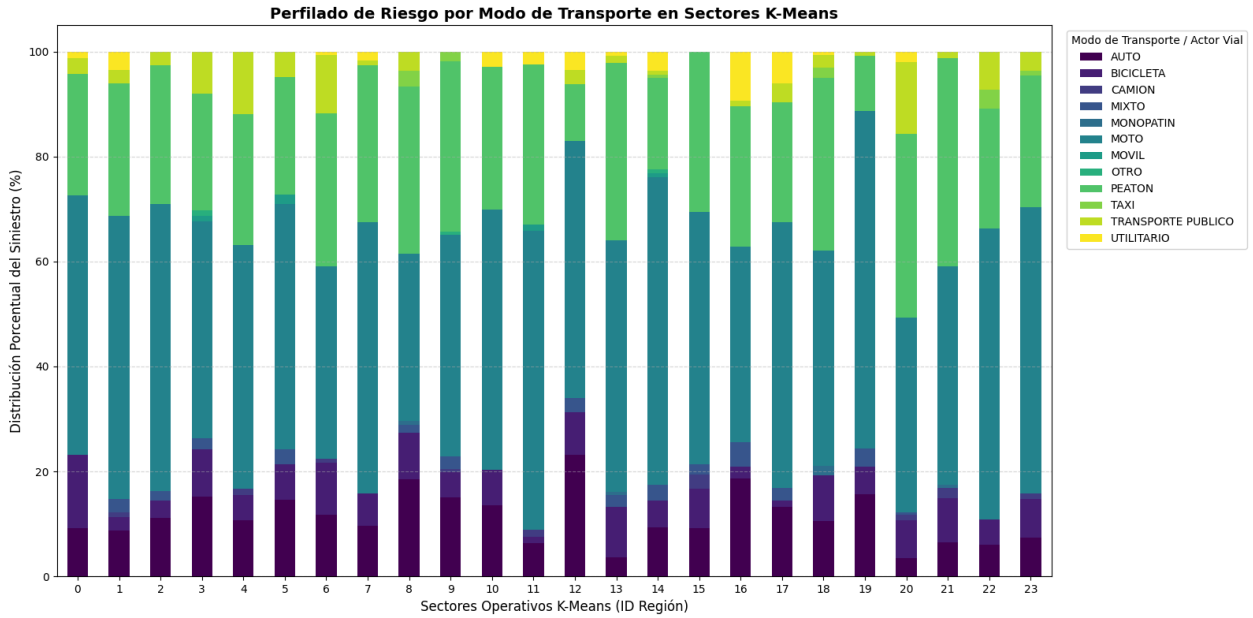
Efecto de densidad de nodos (Total Esquinas): El volumen de siniestros graves tiende a concentrarse en celdas con alta densidad de intersecciones por unidad de área (0,7 km²). Los 10 hexágonos más peligrosos contienen entre 32 y 81 esquinas. Esto confirma que el riesgo está directamente ligado a los puntos de ruptura del flujo vehicular continuado: a mayor cantidad de esquinas dentro de un mismo perímetro, se multiplican geométricamente las trayectorias de cruce y, por ende, los puntos potenciales de conflicto.

Efecto de complejidad geométrica (Complejidad Media): El indicador de complejidad (derivado del atributo `street_count` de OSMnX) revela la naturaleza física del entorno. Los valores oscilan entre 3,42 y 3,93 vías por nodo. Sabiendo que un cruce estándar en cruz tiene un valor de 4, un promedio tan cercano a este límite indica que el Top 10 está compuesto casi en su totalidad por intersecciones completas de 4 vías o nudos viales complejos (intercambiadores, autopistas y rotondas).

5.5 Perfilado de sectores y validación geográfica

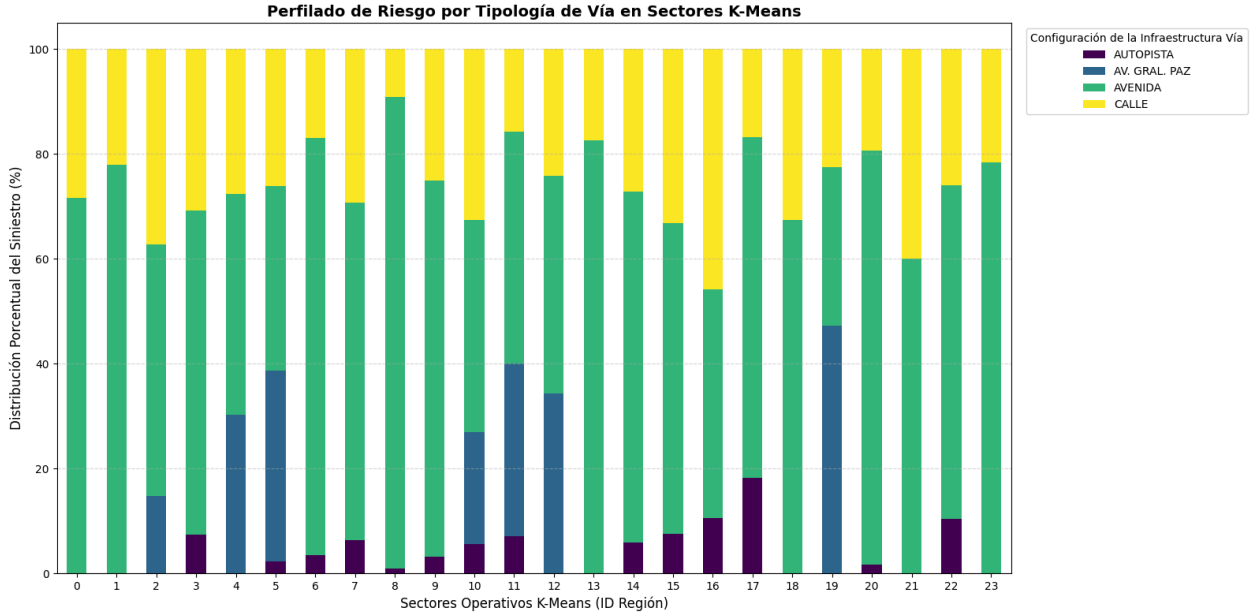
Al cruzar los 24 sectores K-Means con los perfiles de tipo de vía y tipo de usuario, y luego con las Comunas políticas de la ciudad, se valida la precisión del modelo:

Validación del Perfil Peatonal: El Sector 20, identificado con una tasa crítica de accidentes de peatones (~40%), se ubica en un 81,5% dentro de la **Comuna 1**. Esto es plenamente coherente, ya que el Microcentro y Retiro son los nodos de transbordo e intercambio peatonal más densos de la ciudad.



Validación de la Infraestructura Vial: El Sector 19 (caracterizado por la Av. General Paz) se encuentra en un 99,1% dentro de la **Comuna 12**, el límite geográfico norte de CABA. Asimismo, el Sector 17 (predominio de Autopistas) se concentra en la **Comuna 9**, cruzada por los principales conectores e intercambiadores de autopistas del oeste.

Esta consistencia demuestra que el modelo K-Means no tomó decisiones aleatorias: logró absorber la morfología urbana de la ciudad a partir de simples coordenadas geográficas, convirtiéndose en una herramienta confiable para la toma de decisiones.



El análisis DBSCAN aplicado a franjas temporales específicas revela además que:

- **Horario nocturno (2 puntos críticos):** Durante la noche, el flujo de vehículos disminuye pero la gravedad tiende a aumentar. El algoritmo detecta únicamente 2 focos críticos de muy alta concentración, ideales para intervenciones estructurales fijas (radares de velocidad).

- **Horas pico (3 puntos críticos):** Durante los picos de movilidad pendular, el modelo desplaza y amplía sus alertas a 3 focos diferentes, directamente asociados a la congestión, a los nodos de correspondencia y a las fricciones ligadas a un tráfico denso.

Esta dinámica demuestra que una estrategia de seguridad vial basada en un mapa estático anual sería incompleta: los puntos negros son «mutantes» según la hora del día, lo que exige políticas públicas que combinen la modificación de infraestructuras en los 24 nodos identificados con patrullas dinámicas que acompañen la dispersión del riesgo.

```
================================================================================
   ANÁLISIS TEMPORAL AVANZADO: SENSIBILIDAD DEL DBSCAN (NOCHE VS HORA PICO)
================================================================================
Siniestros analizados en horario Nocturno (22:00 a 05:59): 659
-> Puntos negros críticos detectados en la noche: 2
-> Siniestros concentrados en puntos negros nocturnos: 11
--------------------------------------------------------------------------------
Siniestros analizados en Horas Pico (07:00-10:59 / 17:00-20:59): 1194
-> Puntos negros críticos detectados en horas pico: 2
-> Siniestros concentrados en puntos negros de horas pico: 14
================================================================================
```

Conclusión General y Limitaciones del estudio

El despliegue de este pipeline de análisis de datos geoespaciales ha permitido elaborar un diagnóstico completo de la inseguridad vial en Buenos Aires.

En el plano temporal y demográfico, los resultados confirman la existencia de un perfil de riesgo altamente polarizado, caracterizado por una fuerte preponderancia masculina y una vulnerabilidad acrecentada de los usuarios mayores. El análisis de los flujos pone en evidencia el impacto crítico de la fatiga y de la desorganización de los desplazamientos durante la punta vespertina, que registra un incremento del 62% de accidentes respecto a la mañana.

En el plano geográfico, el enfoque espacio-categorial ilustra la separación neta de los riesgos según los modos de transporte (los peatones en el centro histórico de la Comuna 1, el automóvil en los ejes autopistas periféricos). La aplicación del método de Jenks ha revelado una dinámica espacial específica, caracterizada por una concentración de la mortalidad en la corona intermedia (3 a 8 km del centro), refutando los modelos teóricos simples basados únicamente en la velocidad en la periferia.

En el plano de la modelización, la comparación rigurosa de los algoritmos demuestra la inadecuación de K-Means, cuyas particiones geométricas masivas son inexplotables para la gestión urbana. La modelización por DBSCAN (eps = 100 m, min = 8) se impone como el modelo de ayuda a la decisión óptimo. Al aislar con precisión 24 puntos negros estructurales descartando el ruido de fondo de la siniestralidad fortuita, este enfoque provee una cartografía operacional clara para la planificación de aménagements de seguridad vial focalizados y eficaces.

En el plano del análisis avanzado, la indexación hexagonal H3 y el cruce topológico con OSMnX aportan la dimensión causal del análisis. La siniestralidad grave en CABA no es aleatoria: es topológica. Las zonas más peligrosas son aquellas con mayor densidad de cruces complejos (3,4 a 3,9 vías por nodo en promedio). Para la política pública, esto significa que la solución no es solo policial, sino de rediseño de infraestructura: semaforización inteligente, canalización de giros y pacificación del tránsito en los nodos identificados.

Aunque el enfoque metodológico permite aislar con precisión las zonas críticas, hay que señalar algunas limitaciones vinculadas a los datos.

Primero, existe un sesgo de selección importante: al filtrar el dataset para quedarnos solo con la siniestralidad prioritaria (las categorías GRAVE y MORTAL) y excluir la categoría LEVE, el modelo se enfoca únicamente en el riesgo de alta letalidad. Esta exclusión oculta los incidentes menores o los conflictos viales cotidianos que ocurren en las zonas residenciales o en las ciclovías, lo que subestima la peligrosidad real de ciertos barrios. Además, la base sufre un sesgo de subregistro, ya que muchos accidentes leves nunca son registrados por la policía o los hospitales.

Segundo, la distancia al centro urbano se calculó en línea recta (distancia euclidiana) gracias a la proyección Gauss-Kruger. En la realidad, los desplazamientos dependen de la geometría de las calles. Una distancia de red real habría sido más exacta para reflejar el recorrido de los usuarios.

Por último, el análisis carece de datos de exposición, como el flujo de tráfico diario. Sin esto, es imposible saber si un hexágono H3 o un cluster DBSCAN presenta muchos accidentes debido a

un defecto en la infraestructura o simplemente porque pasa diez veces más vehículos que por otros lados. Integrar el volumen de tráfico permitiría calcular una tasa de riesgo relativo real.